

匠心匠造

基于BERT实体抽取的中西医脾
虚证候知识图谱构建与应用

组长：廖家祺

团队成员：吴安杰，徐登恒，张新通

汇报人：廖家祺




研究背景

中医现有数据库匮乏

术语与病历缺乏标准化，数据碎片化难共享；临床数据规模小、质量参差；古籍与名医经验数字化程度低；中药方剂数据关联薄弱；缺乏高质量研究数据库；既懂中医又懂数据科学的复合人才短缺。这严重制约了中医科研现代化与国际化发展

西医标识与中医标识 关联度不高

西医标识（如生化指标、影像结论）与中医标识（如证型、舌脉）缺乏直接对应关系，数据割裂。例如高血压（西医病名）可对应多种中医证型（如肝阳上亢、痰湿内蕴），但临床与科研中两者常孤立记录，缺乏结构化关联数据库，导致中西医结合诊疗与科研难以深入整合。





项目目标

项目目标

研究思路

研究方法

核心技术

成果展示

项目预计完成目标路径探索

信息抽取

1. 利用预训练的BERT模型，从海量中西医文本文献（教材、病历、期刊）中自动识别关键医学实体。



关系构建

2. 抽取实体间的语义关系（如“脾虚证包含症状腹胀”、“黄芪治疗脾虚”）。



图谱构建与存储

3. 将结构化数据导入Neo4j图数据库，形成关联网络



AI-Agent

4. 一个支持智能检索与关系推理的知识系统原型。



核心目标：构建一个**精准、可查询、可视化**的中西医脾虚证候知识图谱。



项目流程概览

项目目标

研究思路

研究方法

核心技术

成果展示

1.数据层

收集与清洗 → 中西医文本
BIO标注文件

2.算法层

标注与训练 → BERT
实体关系联合抽取模型。

3.知识层

构建与存储 → Neo4j知
识图谱。

4.应用层

可视化与查询 → 知识
发现与服务。



项目层级结构

项目目标


研究思路

研究方法


核心技术

成果展示


两大重要节点





中医数据爬取结果部分展示




西医数据爬取结果部分展示



数据清洗阶段核心代码



Bert模型核心展示





项目层级结构

项目目标


研究思路

研究方法

核心技术

成果展示


BIO数据处理




选取的模型

训练模型

输出的中医三元组




输出的西医三元组



爬取数据库数据展示

构建中西医关系映射字典

连接与导入数据至Neo4j



账户密码、三元组以及字典映射存储



知识图谱应用价值

项目目标

研究思路

研究方法

核心技术

成果展示

问题：我们要搭建怎么样的知识图谱？

知识图谱的种类

本体、事实、事理



Graph RAG: 知识图谱结合 LLM 的检索增强



回答：有关各个实体之间相互映射、相互联系的知识图谱



Bert-Crf是什么？

BERT-CRF 是一个经典的序列标注模型架构，

它结合了两种强大的技术：

BERT（Transformer编码器）：

作为模型的“理解层”

CRF（条件随机场）：

作为模型的“决策层”。

映射是什么？图谱之间的映射是什么？

映射是通用的对应规则。

等价、关联、上下位映射、属性映射

图谱之间的映射是为了消解异构知识图谱之间的语义隔阂，实现知识互联、融合与统一访问。



Bert选择


项目目标

研究思路

研究方法

核心技术

成果展示



如何选择合适的Bert模型

通用场景	特点	优势
bert-base-chinese	通用中文，简单可靠	模型体积小（约 400MB 左右）、推理速度快
hfl/chinese - WWM - ext	中文效果优，强推	基于谷歌原始 BERT 架构，预训练规模相对适中 在更大规模的中文语料（新闻、百科、小说等多领域混合）上继续预训练，参数量和训练轮数也有相应扩充； 对中文语义的捕获更细腻，尤其在分词边界模糊、多字词理解任务中表现突出
hfl/chinese - roberta - wwm - ext	数据大时表现优	在超大规模文本分类、长文本摘要、问答系统等“需要吃透长距离依赖 + 细粒度语义”任务中，表现常优于前两者； 此版本又结合了 全词掩码（WWM）思想
nghuyong/ernie - health - zh	请专注医学可尝试	针对医疗文本的特点（专业术语多、句式严谨但表述晦涩、同义词/缩写繁多）做了专项优化。 严格聚焦“医疗健康垂直领域”相关任务时，是首选方案之一；

我该如何训练该模型？

bert-base-chinese	hfl/chinese - roberta - wwm - ext	hfl/chinese - roberta - wwm - ext	nghuyong/ernie - health - zh
通用中文语料收集	多领域中文语料扩充	大规模中文语料整合	医疗专业语料筛选
单字词表构建	全词掩码设计	动态掩码策略	知识增强预训练
MLM预训练	WWM+MLM预训练	去NSP+大批次训练	领域自适应训练
基础任务微调	通用任务微调	复杂任务微调	医疗任务微调



总概

项目目标

研究思路

研究方法

核心技术

成果展示

数据爬取

Pubmed西医数据库与相关论文

中医数据库与相关论文

数据清洗

格式转化

人工+飞书辅助大纲阅读

字典构建

Json格式方便连接数据库

BIO&Bert

BIO编码处理

Bert实体抽取

Neo4J

种类

Aura

Desktop
Community

字典结构&实体结构

中西医

三元组

映射

字典 (mapping) 关系



数据该如何获取?

项目目标

研究思路

研究方法

核心技术

成果展示

中医标准数据库



古籍论文



- | | |
|---------------|---------------|
| [M+] 刺灸灸法学.md | [M+] 推拿治疗学.md |
| [M+] 耳鼻咽喉科学 | [M+] 外科学.md |
| [M+] 方剂学.md | [M+] 温病学.md |
| [M+] 金匱要略.md | [M+] 小儿推拿学.md |
| [M+] 经络腧穴学.md | [M+] 药理学.md |
| [M+] 临床中药学.md | [M+] 药事管理学.md |
| [M+] 内科学.md | [M+] 药用植物学.md |
| [M+] 伤寒论选读.m | [M+] 针灸学.md |
| [M+] 生理学.md | |

映射关系展示 字典核心代码展示

```
def build_disease_to_symptom_mapping(self, triples):
    """从三元组构建疾病到症状的映射"""
    print("开始构建疾病到症状的映射...")

    count = 0
    for triple in triples:
        head = triple.get('head', '')
        relation = triple.get('relation', '')
        tail = triple.get('tail', '')

        # 构建疾病到症状的映射
        if relation == "是":
            if tail not in self.disease_to_symptom[head]:
                self.disease_to_symptom[head].append(tail)
                count += 1

    print(f"构建完成: {len(self.disease_to_symptom)} 个疾病到症状的映射")

def build_symptom_to_disease_mapping(self, triples):
    """从三元组构建症状到疾病的映射"""
    print("开始构建症状到疾病的映射...")

    count = 0
    for triple in triples:
        head = triple.get('head', '')
        relation = triple.get('relation', '')
        tail = triple.get('tail', '')

        # 构建症状到疾病的映射
        if relation == "是":
            if head not in self.symptom_to_disease[tail]:
                self.symptom_to_disease[tail].append(head)
                count += 1

    print(f"构建完成: {len(self.symptom_to_disease)} 个症状到疾病的映射")
```

西医标准数据库



论文



- 伴或不伴神经精神症状的巨幼细胞性贫血临床分析
- 保“胃”健康，科学防治消化性溃疡_于会永.pdf
- 别让高血压危害生命健康_宋玮.pdf
- 补脾益肺汤治疗变应性鼻炎的临床疗效分析_王佩
- 肠道菌群在过敏性哮喘防治中的作用_申圳.pdf
- 儿童、青少年缺铁性贫血的防治方法研究_广西玉
- 儿童哮喘共患病及其发病机制研究进展_沈世平.pd
- 反馈式饮食健康教育对肝癌并发低蛋白血症患者
- 反流性食管炎患者症状严重程度与内镜下分级的
- 反流性食管炎中医证型分布特点及相关因素分析



获取到的数据该如何处理?

项目目标

研究思路

研究方法

核心技术

成果展示

Md文档格式转txt



Markdown文档转为纯文本，保留内容但去除格式标记



删除多余的空白行或残留符号，保存为txt编码



Pdf文档格式转txt



直接从文字型PDF（通常由Word等软件生成）中“抽取”出编码文字



转换后检查格式错乱、乱码等问题，进行简单排版修正



```
total_success = 0
total_errors = 0

# Process Chinese Medicine Science data
src_chinese_dir = os.path.join(base_src_dir, "Data_ChineseMedicineScience")
dst_chinese_dir = os.path.join(base_dst_dir, "Data_ChineseMedicineScience")
print(f"Processing Chinese Medicine Science data...")
if os.path.exists(src_chinese_dir):
    success, errors = process_directory(src_chinese_dir, dst_chinese_dir)
    total_success += success
    total_errors += errors
else:
    print(f"Source directory {src_chinese_dir} does not exist")

# Process Western Medicine data
src_western_dir = os.path.join(base_src_dir, "Data_WesternMedicine")
dst_western_dir = os.path.join(base_dst_dir, "Data_WesternMedicine")
print(f"Processing Western Medicine data...")
if os.path.exists(src_western_dir):
    success, errors = process_directory(src_western_dir, dst_western_dir)
    total_success += success
    total_errors += errors
else:
    print(f"Source directory {src_western_dir} does not exist")
```

代码展示

OCR技术识别



光学字符识别，将PDF页面视为图像



必须进行人工校对，修正错别字



人工筛选



需从文档中提取特定信息或过滤无效内容



抽查结果是否符合要求，确保无遗漏或误删





模型调用过程-BIO

项目目标

研究思路

研究方法

核心技术

成果展示

什么是BIO?



一种序列标注方案，主要用于自然语言处理任务中，用于标识文本中实体的边界位置



B：实体的起始位置



I：实体的内部位置（非起始）

O：非实体部分

BIO核心代码



文本转换为BIO标签的函数



BIO标签解码为实体



```
导入现有的BIO格式化工具
from bio_formatter import sentence_to_bio, write_bio_file

医学实体类型定义
MEDICAL_ENTITY_TYPES = {
    "Disease": "疾病",
    "Symptom": "症状",
    "Medicine": "药物",
    "Herb": "中草药",
    "Formula": "方剂",
    "Syndrome": "证候",
    "Body_Part": "身体部位",
    "Medical_Examination": "检查",
    "Treatment": "治疗方法"
}
```

代码展示

为什么要用BIO



解决实体边界模糊问题
区分相邻的相同类型实体



标准化处理流程
有着独特技术优势



BIO运行展示



可视化标注



边界识别





模型调用过程-BERT

项目目标

研究思路

研究方法

核心技术

成果展示

下载模型



```
from transformers import BertTokenizer, BertModel

# 指定模型名称（第一次运行时会自动下载）
model_name = "hfl/chinese-bert-wwm-ext"

# 指定下载 tokenizer 和 model 的 id
tokenizer = BertTokenizer.from_pretrained(model_name)
model = BertModel.from_pretrained(model_name)

# 测试
text = "带气虚者常带同病于治。"
inputs = tokenizer(text, return_tensors="pt", padding=True, truncation=True)
outputs = model(**inputs)

print("BERT 加载成功!")
print("输入 token IDs:", inputs["input_ids"])
print("输出 shape:", outputs.last_hidden_state.shape) # [1, 128, 768]
```

```
import json
import os
import sys

# 添加上项目到Python路径，以便导入其他模块
sys.path.append(os.path.dirname(os.path.dirname(os.path.abspath(__file__))))

from typing import Dict, List

# 模型路径和输入JSON文件路径
MODEL_PATH = "../models/bert_crf_spleen.pth"
CHINESE_INPUT_JSON = "../输出结果/chinese_entities.json"
WESTERN_INPUT_JSON = "../输出结果/western_entities.json"

def extract_spleen_related_entities(file_type: str) -> List[Dict]:
```

代码展示

训练模型



```
# BERT训练
outputs = self.bert(input_ids=input_ids, attention_mask=attention_mask)
sequence_output = outputs.last_hidden_state

# dropout
sequence_output = self.dropout(sequence_output)

# 分类
logits = self.classifier(sequence_output)

if labels is not None:
    # 计算损失
    loss = self.calculate_loss(logits, labels, attention_mask)
    return loss
else:
    # 预测时返回logits
    return logits
```

调用模型



```
self.num_labels = num_labels

# BERT模型
self.bert = BertModel.from_pretrained(bert_model_name)

# dropout
self.dropout = nn.Dropout(0.1)

# 分类器
self.classifier = nn.Linear(self.bert.config.hidden_size, num_labels)

# CRF模型
self.transitions = nn.Parameter(torch.randn(num_labels, num_labels))

# 初始化权重
nn.init.xavier_uniform_(self.transitions)

def forward(self, input_ids, attention_mask, labels=None):
    """
```

调试模型



```
def main():
    """主函数"""
    print("=== BERT-NEO 医学实体识别模型训练启动 ===")

    # 检查依赖
    if not check_dependencies():
        print("依赖包检查失败，无法继续")
        return 1

    # 检查数据文件是否存在
    bio_file_path = "../输出结果/train_chinese.bio"
    if not os.path.exists(bio_file_path):
        print(f"❌ BIO文件不存在: {bio_file_path}")
        print("请先运行数据预处理脚本生成BIO文件")
        return 1

    # 检查数据文件大小
    file_size = os.path.getsize(bio_file_path)
    file_size_mb = file_size / (1024 * 1024)
    print(f"✅ BIO文件存在且大小: {file_size_mb:.2f} MB")
```



三元组有什么用?

项目目标

研究思路

研究方法

核心技术

成果展示

中医三元组



证候：肾阳虚



证候表现为发热



展示



```
{
  "head": "肾阳虚",
  "relation": "证候表现",
  "tail": "发热"
},
{
  "head": "肾阳虚",
  "relation": "证候表现",
  "tail": "呕吐"
},
{
  "head": "肾阳虚",
  "relation": "证候表现",
  "tail": "咳嗽"
}
```

```
"痰湿": [
  "糖尿病",
  "肝炎",
  "肺炎",
  "高血压",
  "肾炎"
],
"肝郁": [
  "肝炎",
  "肝病",
  "胃炎"
```

代码展示

西医三元组



疾病：肠炎



疾病表现为疼痛，
腹泻等



展示



```
"head": "肠炎",
"relation": "表现为",
"tail": "疼痛"
},
{
  "head": "肠炎",
  "relation": "表现为",
  "tail": "腹泻"
},
{
  "head": "肺炎",
  "relation": "表现为",
  "tail": "咳嗽"
}
```



构建映射字典

项目目标

研究思路

研究方法

核心技术

成果展示

调用数据库



SymMap v2.0 Home Browse Search Download Help Contribute

Introduction

SymMap integrates traditional Chinese medicine (TCM) with modern medicine (MM) through both internal molecular and disease information on herbs, ingredients, targets, as well as the clinical symptoms and diseases they are used to treat. Now, we update the SymMap database into version 2.0 to enhance the recent data update. First, we added medical experts, herbs, symptoms, syndromes and the relationships among them based on new Chinese Pharmacopoeia. Second, we add ingredients and proteins and evidence-based literature and facts that supports these relationships through the combination of medical experts. Third, according to the data of mass spectrometry experiments from Chinese Pharmacopoeia (2020 edition), ingredients into 4 categories, including GC ingredients, blood ingredients, metabolic ingredients, as well as other ingredients. Relationships among symptoms and ingredients are shown as network figures. And a convenient function of 3D pathway map.

Citation

书写规则



```
def build_disease_to_symptom_mapping(self, triples):  
    """从三元组中构建疾病到症状的映射字典"""  
    print("\n构建疾病到症状的映射字典")  
    count = 0  
    for triple in triples:  
        head = triple.get('head')  
        relation = triple.get('relation')  
        tail = triple.get('tail')  
        # 判断关系是否为疾病->症状  
        if relation == '疾病->症状':  
            if tail not in self.disease_to_symptom[head]:  
                self.disease_to_symptom[head].append(tail)  
                count += 1  
    print("\n构建了 {} 个疾病到症状的映射字典, 共 {} 个映射".format(count, len(self.disease_to_symptom)))  
  
def build_syndrome_to_symptom_mapping(self, triples):  
    """从三元组中构建证候到症状的映射字典"""  
    print("\n构建证候到症状的映射字典")  
    count = 0  
    for triple in triples:  
        head = triple.get('head')  
        relation = triple.get('relation')  
        tail = triple.get('tail')  
        # 判断关系是否为证候->症状  
        if relation == '证候->症状':  
            if tail not in self.syndrome_to_symptom[head]:  
                self.syndrome_to_symptom[head].append(tail)  
                count += 1  
    print("\n构建了 {} 个证候到症状的映射字典, 共 {} 个映射".format(count, len(self.syndrome_to_symptom)))
```

映射关系字典

resource

SymMap v2.0, SMDE (疾病) file.xlsx
SymMap v2.0, SMHB (药草) file.xlsx
SymMap v2.0, SMIT (成分) file.xlsx
SymMap v2.0, SMMS (MM症状) file.xlsx
SymMap v2.0, SMSY (证候群) file.xlsx
SymMap v2.0, SMTS (中医症状) file.xlsx
SymMap v2.0, SMTT (目标) file.xlsx

中西医映射关系字典.json

build_mapping_dict.py

build_tcm_wm_mapping.py

example_usage.py

爬取相关数据



SymMap v2.0, SMDE (疾病) file.xlsx
SymMap v2.0, SMHB (药草) file.xlsx
SymMap v2.0, SMIT (成分) file.xlsx
SymMap v2.0, SMMS (MM症状) file.xlsx
SymMap v2.0, SMSY (证候群) file.xlsx
SymMap v2.0, SMTS (中医症状) file.xlsx
SymMap v2.0, SMTT (目标) file.xlsx

人工校对



数据质量与一致性
(格式标准化、去重与合并)



实体边界定义 (明确
实体范围等)





导入Neo4J数据库

项目目标

研究思路

研究方向

核心技术

成果展示

创建账号



访问Neo4j Aura控制台
注册账号并创建免费实例



选择Free Tier免费套餐
等待60秒实例启动完成



连接账号



获取连接信息
URI、用户名、密码配置



配置.env环境变量
验证连接状态



选择工具平台



Neo4j Aura云平台
托管式图数据库服务



使用Neo4j Browser
可视化查询和管理



导入CSV文件



数据来源：中医教材
1500+节点，3800+关系



运行导入脚本
npm run import:tcn





最后的图谱为什么是这个样子?

项目目标

研究思路

研究方向

核心技术

成果展示

多实体



8大类中医实体
1500+ 节点



多层次分类体系
支持1-5级分类




多标签



节点包含code
category
level等属性标签



基于标签的智能搜索
AI智能体自动识别



多联系



3800+ 关系连接
多种关系类型



链式关系图谱（疾病
→穴位→经络→症状
→方剂→中药材）



多形态



4种图谱类型
+ 3种视图模式



交互式可视化
支持拖拽、多种布局算法





视频展示

项目目标

研究思路

研究方向

核心技术

成果展示

医疗技术数据大模型系统



3.33亿级
模型量级



44万
成本数量



555户
医疗机构



6666万人
数据统计



AI大数据模型系统搭配医疗技术共同合作

大数据输入

高效率分析

数据分析系统

可视化结果



数据化智能化流程管理，医疗级行业定义水准发展

医药行业是我国国民经济的重要组成部分，是传统产业和现代产业相结合，一、二、三产业为一体的产业，通过大数据模型来全面提升智能化管理水平。



五大内涵

项目目标

研究思路

研究方向

核心技术

成果展示

医疗改革

医疗行业发展变革巨大



技术研发

10年技术研发迭代



人才培养

国家对医疗先锋者的需要



医疗健康

医疗大健康背景下机会



数据科学

人工智能赋能医学发展





视频展示


项目目标

研究思路

研究方向

核心技术

成果展示





视频展示



项目目标

研究思路

研究方向

核心技术

成果展示

http://10.249.254.38/

SN 少纳言
TCM Graph OS

首页

智能探索

数据分析

3D可视化

少纳言 - 图谱控制台 Neo有 Aura 实时在线

搜索 / 快捷命令 300

节点 6,820+

关系 43,542

切换视图模式 SN

VISUALIZATION LAB

高级可视化

在一个舞台上切换多种视角：3D 图谱漫游、时间线剖面、节点演化推演。

根节点: A01

深度: 3

节点限制: 100

加载状态: 就绪

图谱控制

参数配置

根节点

A01,

或从列表选择

外感病类术语 疾病类

深度

3

节点限制

100

快速选择

A01 - 外感病证 B04 - 气血津液病证 B04.03.01.03. - 脾虚

图谱统计

图谱规模

节点总数

0

16:32

2025/12/8

大多数优秀的程序员从事编程工作，不是因为期望获得报酬或得到公众的称赞，而是因为编程是件有趣的事儿。

——林纳斯·托瓦兹

Linus Torvalds

