



南京工业大学
NANJING TECH
UNIVERSITY

用户数据采集与关联分析

(LJQ结课作业)



廖家祺

15380812530

liaojiaqi369963@163.com



南京工业大学
NANJING TECH
UNIVERSITY

01 文本数据分析



廖家祺

15380812530

liaojiaqi369963@163.com


第一讲 课程导言与分词_作业要求

1. 学习使用在线NLPIR分词系统或微词云分词或清华大学分词演示系统（**案例演示截图**）；
2. 安装python（anaconda）（**编写输出“ ”**）；Hello World. Hello ‘**你的姓名**’
3. 完成课后作业（**001-004，4份代码的运行**）。
4. 阅读压缩文件中（“实体抽取论文-换成PDF”）中的其中一篇论文，并做阅读总结（1页PPT即可）（**仅信管**）。
5. 谈一谈在营销学科/领域，文本、文本分词以及实体的内涵。例如：客户关系管理中，文本分析的价值。（**仅营销**）


第一讲 课程导言与分词_作业1_NLPIR

- NLPIR该分词工具目前不支持在线的直接使用功能，好在我再在github上找到了其开源的资源，经过仔细地浏览之后发现，该资源使用Java语言&C语言书写的，本地部署起来较为麻烦，故而我转换思路，从GitHub上找到了用python封装后的NLPIR资源，阅读其相关笔记，配置步骤如下：


第一步，安装python封装的包pynlpir



第二步，在nlpir资源中下载win64的证书信息



第三步，替换掉包中的证书信息



第一讲 课程导言与分词_作业1_NLPIR

- 配置好环境之后，对NLPIR工具在Jupyter notebook中引用书写代码，用来检验分词效果，但发现，该分词工具在几年前变为半开源，故而无法连接接口，但若付费，遵循上述步骤是可以完成代码的运行，调用代码进行简单的分词如下图所示：

书写的调用测试代码

```
[ ]: pip install pynlpir
Collecting pynlpir
  Using cached pynlpir-0.6.1-py3-none-any.whl.metadata (3.5 kB)
Requirement already satisfied: click==8.1 in d:\anaconda3\anaconda\lib\site-packages (from pynlpir) (8.1.8)
Requirement already satisfied: colorama in d:\anaconda3\anaconda\lib\site-packages (from click==8.1->pynlpir) (0.4.6)
Using cached pynlpir-0.6.1-py3-none-any.whl (13.1 MB)
Installing collected packages: pynlpir
Successfully installed pynlpir-0.6.1
Note: you may need to restart the kernel to use updated packages.

[ ]: pip install --upgrade pynlpir
Requirement already satisfied: pynlpir in d:\anaconda3\anaconda\lib\site-packages (0.6.1)
Requirement already satisfied: click==8.1 in d:\anaconda3\anaconda\lib\site-packages (from pynlpir) (8.1.8)
Requirement already satisfied: colorama in d:\anaconda3\anaconda\lib\site-packages (from click==8.1->pynlpir) (0.4.6)
Note: you may need to restart the kernel to use updated packages.

[ ]: pynlpir.update()

-----
AttributeError                                Traceback (most recent call last)
Cell In[6], line 1
----> 1 pynlpir.update()

AttributeError: module 'pynlpir' has no attribute 'update'
Fix Code

[ ]: import pynlpir

[ ]: pynlpir.open()

[ ]: s = "NLPIR分词系统前身是2008年发布的ICTCLAS词法分析系统，从2009年开始，为了和以前工作进行大的区别，并推广NLPIR自然语言处理与信息检索共享平台，调整命名为NLPIR分词"

[ ]: ret = pynlpir.segment(s)

[ ]: print(ret)
```

第一讲 课程导言与分词_作业2_清华大学分词

访问THULAC清华分词官网，使用课程中的PPT备注中的内容进行测试，测试结果如右图所示

THULAC: 一个高效的中文词法分析工具包

欢迎使用THULAC中文分词工具包demo系统

黄旭华，1926年3月12日出生于广东省汕尾市，原籍广东省揭阳市。1949年毕业于上海交通大学，历任北京海军核潜艇研究室副总工程师，中船重工集团公司核潜艇总体研究设计所研究员、名誉所长，1994年当选为中国工程院院士。

测试 Try

黄旭华_np : _w 1926年_t 3月_t 12日_t 出生_v f_广东_省_汕尾市_ns : _w 原籍_广东_省_ns 揭阳市_ns : _w 1949年_t 毕业_v 于_p 上海_交通_大学_n1 : _w 历任_v 北京_海军_n 核潜艇_研究_室_n 副总_工_程师_n : _w 中_心_船_重_工_集团_公司_n 核潜艇_总体_研究_v 设计_所_n 研究员_n : _w 名誉_所长_n : _w 1994年_t 当选_v 为_v 中国_ns 工程院_n 院士_n

词性解释


n/名词 np/人名 ns/地名 ni/机构名 nz/其它专名
m/数词 q/量词 mq/数量词 t/时间词 e/方位词 s/处所词
v/动词 va/能愿动词 vd/趋向动词 a/形容词 d/副词
h/前接成分 b/后接成分 l/习语 j/简称
r/代词 c/连词 p/介词 u/助词 y/语气助词
e/叹词 o/拟声词 g/语表 w/标点 x/其它

版权所有：清华大学自然语言处理与社会人文计算实验室

Copyright: Natural Language Processing and Computational Social Science Lab, Tsinghua University

第一讲 课程导言与分词_作业3

在jupyter中创建name_hellow_text文件，并且输出Hello World. Hello ‘你的姓名（Tycho廖家祺）’ 结果如下图所示：



The screenshot displays the JupyterLab web interface. At the top, the browser address bar shows 'jupyter name_hellow_text' and 'Last Checkpoint: 39 seconds ago'. The interface includes a menu bar with 'File', 'Edit', 'View', 'Run', 'Kernel', 'Settings', and 'Help'. Below the menu bar is a toolbar with icons for file operations and code execution. The main area contains a code cell with the following content:

```
[3]: print("Hello World. Hello 'Tycho廖家祺'")  
Hello World. Hello 'Tycho廖家祺'
```

The code cell is currently selected, and the output of the previous execution is visible below the code. The output is 'Hello World. Hello 'Tycho廖家祺''. The interface also shows a 'Trusted' status indicator and a 'Python [conda env:base] *' environment selector.

第一讲 课程导言与分词_作业4

选取“基于学术论文全文内容的算法使用行为及其影响力研究_章成志”论文阅读



阅读总结：

本文以自然语言处理领域为例，基于1993—2016年全国计算语言学会议（CCL）论文全文数据，系统考察了十大数据挖掘算法的使用行为及其影响力。研究从使用频次、使用位置、使用年代和使用动机四个维度展开分析。结果显示，SVM算法在提及论文数、章节分布及年代演变中均表现突出，影响力最高；CART与Apriori算法使用频次低，影响力较弱。研究还发现算法在学术论文中既作为实际方法被应用，也常作为背景被提及，使用动机以“单一使用”和“使用并比较”为主。该研究为算法影响力评估提供了基于全文内容的多维分析方法，可为领域内研究者在算法选择时提供实证参考。

第二讲 词频统计_作业要求

1. 基于CNKI数据库统计分析2014-2024年（近10年），“信息资源管理”或“网络营销”或其他你感兴趣的主题变化趋势。
2. 完成ppt中的程序运行，包括全文词频统计，指定类型词频统计；
3. 链接功勋科学家：把ppt中的文本换成功勋科学家黄旭华院士的传记序言文本（文件夹中，科学家博物馆-黄旭华传记序言.txt），1）统计全文词频；2）统计指定词频，如“黄旭华”；
4. 阅读论文“2018-Wang 等 - Long live the scientists Tracking the scientific”，并做阅读总结（1页PPT即可）。

第二讲 词频统计_作业1_基于CNKI数据库分析生态经济

部分检索展示，主要划取近十年期刊，主题词选取生态经济，期刊选取核心与会议

cnki中国知网

www.cnki.net

文献期刊硕博会议报纸图书年鉴工具书专利标准成果更多

高级检索专业检索作者发文检索句子检索一框式检索

文献分类目录

基础科学工程科技I期工程科技II期农业科技医药卫生科技哲学与人文科学社会科学I期社会科学II期信息科技经济与管理科学

为我推荐

户外行人热舒适评价模型研究述评中国生态经济研究：历史脉络、理论梳理及未来展望

输入检索条件:

主题生态经济

并含

词频

并含

词频

精确

并且

关键词

词频

并含

词频

精确

作者

中文字/英文书/图表

精确

作者单位

全称/简称/曾用名

模糊

从2015年到2025年

指定日期

更新时间

不限

来源期刊

期刊名称/ISSN/CN

模糊

来源类型

☐全部期刊☒SC来源期刊☒EI来源期刊☒核心期刊☒CSSCI☒CSCD

支持基金

基金

精确

☐包含资源☐网络首发☐增强出版☐数据论文☒中英文扩展☐同义同扩展

检索

结果中检索

免费订阅

分组浏览:


主题发表年度研究层次作者机构基金

生态文脉建设 (253)绿色经济 (207)生态文明 (200)生态环境 (254)耦合协调发展 (202)生态经济 (170)高质量发展 (104)耦合协调 (103)

绿色发展 (130)黄河流域 (130)绿色发展 (100)数字经济 (107)协调发展 (103)数字经济 (90)生态经济 (90)


第二讲 词频统计_作业1_基于CNKI数据库分析生态经济

展示主题趋势




第二讲 词频统计_作业1_基于CNKI数据库分析生态经济


展示2015主题趋势




展示2023主题趋势



展示2018主题趋势



展示2025主题趋势





第二讲 词频统计_作业1_基于CNKI数据库分析生态经济

主题词趋势分析结果如下：

1. 从2015年至2025年生态经济期刊主题词的变化趋势来看，研究主题呈现“从宏观、基础概念向具体、前沿、实践导向的演变”，体现了学科交叉深化与现实问题紧密结合的特点。
2. 2015年以“可持续发展”“生态系统”“生物多样性”等为核心，关注宏观生态经济关系；2018年已出现“绿色金融”“低碳转型”等实践性议题；至2023年，“碳中和”“生态补偿”“循环经济”成为热点，政策与技术导向明显；2025年则进一步聚焦“气候韧性”“数字生态治理”“生态产品价值实现”等前沿议题，体现研究趋向系统化、精细化与工具化。
3. 整体来看，主题演变反映了生态经济学从理论探讨走向政策工具与治理实践，同时与全球气候议程、数字化转型等时代议题深度融合。

第二讲 词频统计_作业2_ppt中的程序运行_全文词频统计

全文词频统计、PPT代码，三国板块



第二讲 词频统计_作业2_ppt中的程序运行_指定类型词频统计

指定类型词频统计、PPT代码，三国板块

```
[1]: f_name = open('name.txt')
[2]: data_name = f_name.read()
[3]: data_name[:70]
[4]: '诸葛亮|关羽|刘备|曹操|孙权|周瑜|鲁肃|黄忠|马超|'
[5]: print(data_name[:50])
    诸葛亮|关羽|刘备|曹操|孙权|周瑜|鲁肃|黄忠|马超|
[6]: f_name.close()
[7]: # 将文本拆分为列表
[8]: names = data_name.split('|') # split 将文本拆分为列表
[9]: print(names)
[10]: ['诸葛亮', '关羽', '刘备', '曹操', '孙权', '周瑜', '鲁肃', '黄忠', '马超']
[11]: names
[12]: ['诸葛亮', '关羽', '刘备', '曹操', '孙权', '周瑜', '鲁肃', '黄忠', '马超']
[13]: # 学习一种新的数据结构：字典
[14]: name_dict = {}
```

```
你又有发现下面的代码片段吗？data_txt.count(name)，就可以统计词！实际上是统计字符串的过程！
[15]: for name in names:
    name_dict[name] = data_txt.count(name)
[16]: name_dict
[17]: {'诸葛亮': 149,
      '关羽': 8,
      '刘备': 291,
      '曹操': 907,
      '孙权': 315,
      '周瑜': 347,
      '鲁肃': 332,
      '黄忠': 235,
      '马超': 301,
      '魏延': 80,
      '司马懿': 272,
      '黄忠': 179,
      '马超': 212}
[18]: # 定义 画图 函数
[19]: def make_chinese_plot_ready():
    from matplotlib import rcParams
    rcParams['font.family'] = 'chinese' # 将字体设置为中文字体
    rcParams['font.sans-serif'] = ['FangSong'] # 将字体设置为方正宋体 FangSong
    rcParams['axes.unicode_minus'] = False
[20]: # 定义 画图 函数
[21]: def draw_dict(mydict, figsize=(8, 5)):
    import pandas as pd
    import matplotlib.pyplot as plt
    make_chinese_plot_ready()
    df = pd.DataFrame(list(mydict.items()), columns=['name', 'times'])
    df.set_index('name')['times'].sort_values(ascending=False).plot(kind='bar', figsize=figsize) # 排序并
    plt.tight_layout()
[22]: # Jupyter inline
[23]: %matplotlib inline
```


第二讲 词频统计_作业3_替换文本程序运行_指定类型词频统计

指定类型词频统计、PPT代码，黄旭华板块

```
[16]: f_txt = open('科学家博物馆-黄旭华传记序言.txt',encoding = 'utf-8')  
[17]: data_txt = f_txt.read()  
[18]: f_txt.close()  
[19]: print(data_txt[:1000])
```

在核潜艇领域，我国已形成一套完整的研究、设计、试验、制造、测试的核潜艇产业体系，而且装备了一支具有极高战略威慑力的、成梯次配备的、已近实现战备巡逻的核潜艇部队。回顾我国核潜艇的发展历程，人们自然会想起以黄旭华为代表的五位两院院士及无数第一代核潜艇研制人员的筚路蓝缕、无私奉献，正是他们所铸就的国之重器使我国彻底摆脱了超级大国的核讹诈，更使我们在民族复兴的道路上迈出了坚实的一步。

而今，由黄旭华院士等人所开创的核潜艇工程以令世人震撼的力量，继续承载着捍卫“中国梦”的伟大重任。

黄旭华是我国著名船舶专家、核潜艇研究设计专家、中国工程院首批院士、中国第一代核动力潜艇研制创始人之一。1924年2月24日，黄旭华出生于广东省汕尾市海丰县田墘镇，原籍广东省揭阳县。1949年，他毕业于国立交通大学造船系船舶制造专业，先后从事过民用船舶和军用舰艇的研究设计工作。1958年，黄旭华开始参与并领导我国第一代核潜艇的研究设计工作，先后出任第一代核潜艇副总设计师、第二任总设计师，历任中国船舶工业总公司及中船重工集团公司第七一九所副总工程师、副所长、所长、党委书记。黄旭华先后于1978年获全国科学大会奖、1982年获国防科工委二等奖，1986年被授予船舶工业总公司劳动模范，1989年被授予全国先进工作者，他参与完成的我国第一代核潜艇研制获1985年国家科学技术进步奖特等奖、导弹核潜艇研制获1996年国家科学技术进步奖特等奖。

黄旭华出生于以医为主、兼理农商之家，正直、勇敢、仁厚、坚毅的父母自小给予了他良好的道德与文化的熏陶，在历经了树基小学、作矶小学、掌怀中学、广益中学、桂林中学、教育部特设大学先修班的坎坷求学历程之后，他以优异的成绩进入了当时著名的国立交通大学，系统学习造船专业理论与技术，以期实现“科学强国”的报国理想，同期在地下党的培养下，历经风雨的洗礼成长为一名坚强的共产党员。

新中国成立后，经过党校系统培训学习，黄旭华在政治思想上逐步成熟。经过苏联军事舰艇的转让仿制的锤炼，黄旭华在专业技术上也崭露头角。1958年，黄旭华因为政治素质过硬、专业技术精湛，成为开启“89工程”的最初29位专业技术人员之一，从此将自己的一生

```
[20]: # 用count函数统计文本中的词汇
```

```
[26]: 1 for term in terms:  
2     terms_dict[term]=data_txt.count(term)
```

```
[27]: 1 terms_dict
```

```
[27]: {'黄旭华': 59, '核潜艇': 32, '国立交通大学': 3}
```

```
[28]: 1 # 定义 画图 函数
```

```
[29]: 1 def make_chinese_plot_ready():  
2     from matplotlib import rcParams
```

第二讲 词频统计_作业4_阅读总结

阅读感想：

通过阅读这四篇论文发现：均关注利用文本数据量化分析特定实体的影响力，但研究目标与方法各有侧重。

1. 《基于学术论文全文内容的算法使用行为及其影响力研究》以学术论文全文为基础，通过词频、使用位置、年代分布与使用动机四个维度，系统评估十大数据挖掘算法在NLP领域的影响力，提出SVM影响力最高，CART与Apriori较低。该方法强调了从全文内容挖掘算法使用模式的价值。
 2. 《Long live the scientists: Tracking the scientific fame of great minds in physics》则基于谷歌图书和谷歌学术的语料库，以牛顿与爱因斯坦为例，通过词频分析追踪科学家的持久影响力，揭示了“组内偏好”现象，并提出图书语料可拓展为衡量科学家社会影响的补充指标。
 3. 《文本的阅读复权——从福柯文本的词频统计复归其原初思想构境》通过对福柯关键概念的法文词频分析，探讨其在哲学思想演变中的核心术语变化，旨在还原被翻译遮蔽的学术原境，体现了文本细读与量化统计结合的文献阐释路径。
 4. 《生态经济期刊主题词变化趋势（图）》虽未提供全文，但从主题词演变可见学科研究从宏观生态理论向微观实践（如碳中和、数字治理）逐步聚焦，反映了生态经济学领域与现实政策的深度融合趋势。
- 结合阅读感想看来，这四篇论文共同展示了基于文本内容。学术文献、图书、主题词的量化方法在评估算法、科学家、哲学思想与学科趋势等方面的广泛应用。它们均重视时间维度分析，强调语境与动机区分，并主张将量化分析与定性阐释相结合，以更全面、客观地揭示研究对象的演变轨迹与影响力机制。

第三讲 词云与可视化_作业要求

1. 用任意一款词云工具，制作一个好看的词云（内容合理即可），并对词云图有一段话的解释。
2. 使用Echarts，制作3个以上图，其中一个必须是“关系”，图的概念越明确（可解释，而不是自带的模板）越好。
3. 使用Gehpi、VOSViewer、CiteSpace…其中任意一款工具，绘制任意你感兴趣的图谱1-2张。
4. 采用给的程序，实现一段科学家文本的词云图绘制，越清晰越好（生成的词云图要单独拿出来）。

第三讲 词云与可视化_作业1_制作一个好看的词云图

生态经济相关词云图：



词云图解释：

该词云图呈现了可持续发展领域的核心关键词，如“系统治理”“生态经济”“碳中和”“公正转型”“循环经济”和“韧性”，反映出当前研究聚焦于生态文明建设、绿色经济转型与气候治理的融合，强调制度创新、社会公平与生态系统协同发展的整体性治理思路。

第三讲 词云与可视化_作业2_ Echarts绘图

步骤一、思路简介:

Echarts是基于JS的一款开源可视化工具，所以在我不使用其中实例的情况下，绘制出三张图片需要我在HTML标签的基础上，使用NPM库来安装ECHARTS，使用其强大的渲染引擎，在Vscode中绘制出来

步骤二、小惊喜:

在使用NPM库来安装ECHARTS的过程中，我点击了快速文档，发现有更加不需要下载就可以安装echarts库的方式，虽然快速手册没有提及，但是我点击进去研究一下，发现确实可行，将我发现快捷安装过程附在下面:


1.点击快速上手，进入该连接



2.在该链接中查询file



3.点击找到的文档，复制到本地即可



第三讲 词云与可视化_作业2_ Echarts绘图_展示

!!!

我将绘制出三张图片的代码放置在此张幻灯片的备注中，老师有兴趣可以查看，接下来展示第一个图：南丁格尔玫瑰图

图表展示：



图表说明：

图表说明

南丁格尔玫瑰图 (Nightingale Rose Chart)，也称为极区图，是一种特殊的饼图，由弗洛伦斯·南丁格尔 (Florence Nightingale) 发明，用于展示数据的周期性变化。

本图表展示内容：展示了20个不同产品类别的销售数据分布情况。每个扇形的半径长度和面积大小代表该类别销售额的高低，面积越大表示销售额越高。

图表特点：

- 使用玫瑰图类型 (roseType: 'area')，通过半径和面积的组合来表现数据大小
- 颜色区分不同类别，便于对比各产品类别的销售表现
- 支持交互式查看，鼠标悬停可显示具体数值和百分比
- 图例可滚动，适应多类别数据的展示需求

适用场景：适合展示分类数据的对比，特别适合类别数量较多的情况，能够直观地看出各类别之间的差异。

第三讲 词云与可视化_作业2_ Echarts绘图_展示

!!!

我将绘制出三张图片的代码放置在此张幻灯片的备注中，老师有兴趣可以查看，接下来展示第二个图：关系图

图表展示：

2. 红楼梦人物关系图



图表说明：

图表说明

关系网络图 (Graph/Network Diagram)，也称为力导向图。用于展示实体之间的关联关系。本图表采用力导向布局算法，能够自动优化节点位置，使关系网络更加清晰。

本图表展示内容：展示了《红楼梦》中32位主要人物之间的复杂关系网络。图中包含5类人物：主角、女性角色、长辈、中辈和丫鬟。节点大小代表人物的重要性。连线表示人物之间的关系强度。

图表特点：

- 力导向布局：使用物理模拟算法自动排列节点位置，相关人物会自动聚集在一起
- 节点大小：节点越大，表示该人物在小说中的重要性越高
- 连线粗细：线条越粗，表示人物之间的关系越密切
- 颜色分类：不同颜色代表不同类型的人物，便于区分角色类型
- 交互功能：支持拖拽节点、缩放视图、鼠标悬停查看详细信息

数据说明：本图表包含32个节点和50+条关系连线，涵盖了《红楼梦》中的主要人物及其关键关系，如贾宝玉与林黛玉、薛宝钗之间的情感纠葛，贾母与众仆的关系等。

适用场景：适合展示社交网络、组织结构、知识图谱等复杂关系数据，能够直观地呈现实体间的关联和层级关系。


第三讲 词云与可视化_作业2_ Echarts绘图_展示

!!!

我将绘制出三张图片的代码放置在此张幻灯片的备注中，老师有兴趣可以查看，接下来展示第三个图：箱线图

图表展示：

3. 箱线图



图表说明：

图表说明

箱线图 (Box Plot)，也称为盒须图，是一种用于显示数据分布的统计图表。能够直观地展示数据的五个关键统计量：最小值、第一四分位数 (Q1)、中位数 (Median)、第三四分位数 (Q3) 和最大值。

本图表展示内容：展示了13个不同学科的学生成绩分布情况。每个箱线图展示了该学科的成绩分布特征，包括数据的离散程度、中位数位置、异常值等信息。

图表元素解读：



- 箱体 (Box)：箱体的下边界是Q1 (第一四分位数)，上边界是Q3 (第三四分位数)，箱体中间的横线是中位数
- 箱体高度：表示四分位距 (IQR = Q3 - Q1)，反映了数据的离散程度，箱体越高说明成绩分布越分散
- 上须线：从箱体上边界延伸到最大值，表示成绩的上限范围
- 下须线：从箱体下边界延伸到最小值，表示成绩的下限范围
- 异常值：超出上下须线的点可能异常值，表示特别高分或特别低分的情况

数据说明：每个学科的数据基于150名学生的成绩模拟生成，使用正态分布算法确保数据的真实性和代表性。不同学科的平均分和标准差各不相同，反映了各学科的难度差异和学生学习情况的差异。

适用场景：箱线图非常适合用于比较多个组别或类别的数据分布，能够快速识别数据的集中趋势、离散程度和异常值，常用于成绩分析、质量监控、统计分析等领域。

第三讲 词云与可视化_作业3_CiteSpace图谱绘制展示

这两幅图谱是上学期参加正大杯时绘制的关于VR虚拟旅游相关的cite space关键词聚类图谱，正好放置在此处



第三讲 词云与可视化_作业4_给定程序绘制图谱

运行代码展示区块

绘制出的调整的词云图



第四讲 情感分析_作业要求

1. 使用PPT给的情感分析平台（或其它平台），对文本情感进行分析，并截图；
2. 完成sentiment_analysis_1-sentiment_analysis_4, 4份代码。做截图，并简要做代码运行总结分析。
3. 谈一谈情感分析在营销学科/领域的应用以及价值；并且分析大语言模型（LLM）在该领域可能带来的新应用与新改变（**仅营销**）。

第四讲 情感分析_作业1_情感分析TEXT

访问了HanLp网址，进行情感分析的测试，选取的文本为李淳罡颂扬文本（已放置在幻灯片备注中），便于分析查看情感分析的可信度

看起来分析十分到位，颂扬类文本应该就是十分正向的



参考网址在这里

丢失，需要安装情感分析的运行环境，也就是一些必要的程序的

- `anaconda prompt` 运行

```

[ntsk_data] pip install snowbig
[ntsk_data] pip install -U textblob
[ntsk_data] python -m textblob.download_corpora

Requirement already satisfied: snowbig in d:\anaconda\anaconda\lib\site-packages (0.12.1)
Requirement already satisfied: textblob in d:\anaconda\anaconda\lib\site-packages (0.14.4)
Requirement already satisfied: nltk<3.9 in d:\anaconda\anaconda\lib\site-packages (from textblob) (3.5.1)
Requirement already satisfied: click in d:\anaconda\anaconda\lib\site-packages (from nltk<3.9->textblob) (8.1.4)
Requirement already satisfied: joblib in d:\anaconda\anaconda\lib\site-packages (from nltk<3.9->textblob) (1.4.2)
Requirement already satisfied: regex<2022.8.5 in d:\anaconda\anaconda\lib\site-packages (from nltk<3.9->textblob) (2024.11.4)
Requirement already satisfied: tqdm in d:\anaconda\anaconda\lib\site-packages (from nltk<3.9->textblob) (4.67.1)
Requirement already satisfied: colorama in d:\anaconda\anaconda\lib\site-packages (from click->nltk<3.9->textblob) (0.4.4)
Finished

[ntsk_data] Downloading package brown to
[ntsk_data] C:\Users\IAQ1IAQ\AppData\Roaming\nltk_data...
[ntsk_data] Package brown is already up-to-date
[ntsk_data] Downloading package punkt_tab to
[ntsk_data] C:\Users\IAQ1IAQ\AppData\Roaming\nltk_data...
[ntsk_data] Package punkt_tab is already up-to-date
[ntsk_data] Downloading package wordnet to
[ntsk_data] C:\Users\IAQ1IAQ\AppData\Roaming\nltk_data...
[ntsk_data] Package wordnet is already up-to-date
[ntsk_data] Downloading package averaged_perceptron_tagger_eng to
[ntsk_data] C:\Users\IAQ1IAQ\AppData\Roaming\nltk_data...
[ntsk_data] Package averaged_perceptron_tagger_eng is already up-to-
[ntsk_data] date!
[ntsk_data] Downloading package conll1000 to
[ntsk_data] C:\Users\IAQ1IAQ\AppData\Roaming\nltk_data...
[ntsk_data] Package conll1000 is already up-to-date
[ntsk_data] Downloading package movie_reviews to
[ntsk_data] C:\Users\IAQ1IAQ\AppData\Roaming\nltk_data...
[ntsk_data] Package movie_reviews is already up-to-date/

```

Text: 我们共同携手，为之共同努力。”

[illegible]

```
[19]: from sklearn import svm, datasets
```

```

[30]  test_an = BreakNP(test_an)

```

```
[37]: # 遍历sentence中的每个词
for sentence in senti_mn.sentences:
    print(sentence)
```

```
[10] senti_cn_1 = Sentiment(senti_cn.sentences[0])
```

```

10 # 一个列表的索引值，从1到N，test1中N个test1中N个
11 # 其中，test1中N个test1中N个，test1中N个test1中N个
12 test1_cn_1, test1_cn_2

```

[34] G. STROBER, 1999

```

100:         kurtosis_val = kurtosis(P(kurtosis_val, test_statistics[i]))

```

```

[01]  seth_gm_1.seth_gm

```

这使你确定发现了问题——“加总”这个词表达了知识组织中的当前情境。为什么你仍然阻止的？

这是因为SnowNLP的统计方法不同，SnowNLP的微博分析数据，通过处理“这句话代表正面情绪的概率”，也是发现，对于今天微博热门一语，SnowNLP认为，它表示正面情绪的概率没有很高。

这样解释就是ok了

2

```
[15] text = "I am happy today. I feel sad today."
[16] from textblob import TextBlob
[17] blob = TextBlob(text)
[18] blob
[19] TextBlob("I am happy today. I feel sad today.")
[20] # 提取不同的句子成分？
[21] # 用事先定义的文本函数进行了拆分，返回一个
[22] blob.sentences
[23] [Sentence("I am happy today."), Sentence("I feel sad today.")]
[24] blob.sentences[0].sentiment
[25] Sentiment(polarity=0.8, subjectivity=1.0)
[26] # 上述的结果十分有趣吧？
[27] # 极性得分 0.8，主观性得分 1.0，说明一句，情感倾向性非常强烈是+1，-1，-1
[28] # 而主观性得分接近 1，说明这个句子是主观
[29] blob.sentences[1].sentiment
[30] Sentiment(polarity=-0.5, subjectivity=1.0)
[31] # 极性并不为极端值了
[32] blob.sentiment
[33] Sentiment(polarity=0.150989060000000000, subjectivity=1.0)
[34] # 在情感分析领域有这样一个说法：“一言为定”，一言为定，也是从最初以来
[35] # 用事先定义的函数，来提取文本中有用的信息，我们这里用到了“情感”这个词，
```

```
taxi_taxi01 = "显示结果：挺好的" # 运行结果：只靠运气靠运气 拍脑袋：拍脑袋就是好的 毛糙糙的：一天一冲 总结：只靠运气毛糙，用了一天的运气"
```

```
[11] tacban_1 = SwoodIP(text_tacban_1)
```

1181 `taobao_1.swf`

[14] H. 000007261160611

```
[10]: text_taobao_2 = "然而，这是真还是不满意的一部手机？两千多元的手机这样，真的值吗？"
```

```

[10] taobao.J = Snowd.P(text.taobao.J)

```

```
[17]: for sentence in taobao_1.sentences:
      print(sentence)
```

总结：这是我用过最不满意的一款手机，两千多元的手机，这样真的很不值。

```
[18] taobao_1.sentiment
```

0.00000139446234

[22] ● 以上兩項學說均為虛構

```
text_factor_3 = "4"
```

1999, 2000, 2001, 2002, 2003, 2004, 2005, 2006, 2007, 2008, 2009, 2010, 2011, 2012, 2013, 2014, 2015, 2016, 2017, 2018, 2019, 2020, 2021, 2022, 2023, 2024, 2025, 2026, 2027, 2028, 2029, 2030, 2031, 2032, 2033, 2034, 2035, 2036, 2037, 2038, 2039, 2040, 2041, 2042, 2043, 2044, 2045, 2046, 2047, 2048, 2049, 2050, 2051, 2052, 2053, 2054, 2055, 2056, 2057, 2058, 2059, 2060, 2061, 2062, 2063, 2064, 2065, 2066, 2067, 2068, 2069, 2070, 2071, 2072, 2073, 2074, 2075, 2076, 2077, 2078, 2079, 2080, 2081, 2082, 2083, 2084, 2085, 2086, 2087, 2088, 2089, 2090, 2091, 2092, 2093, 2094, 2095, 2096, 2097, 2098, 2099, 2100, 2101, 2102, 2103, 2104, 2105, 2106, 2107, 2108, 2109, 2110, 2111, 2112, 2113, 2114, 2115, 2116, 2117, 2118, 2119, 2120, 2121, 2122, 2123, 2124, 2125, 2126, 2127, 2128, 2129, 2130, 2131, 2132, 2133, 2134, 2135, 2136, 2137, 2138, 2139, 2140, 2141, 2142, 2143, 2144, 2145, 2146, 2147, 2148, 2149, 2150, 2151, 2152, 2153, 2154, 2155, 2156, 2157, 2158, 2159, 2160, 2161, 2162, 2163, 2164, 2165, 2166, 2167, 2168, 2169, 2170, 2171, 2172, 2173, 2174, 2175, 2176, 2177, 2178, 2179, 2180, 2181, 2182, 2183, 2184, 2185, 2186, 2187, 2188, 2189, 2190, 2191, 2192, 2193, 2194, 2195, 2196, 2197, 2198, 2199, 2200, 2201, 2202, 2203, 2204, 2205, 2206, 2207, 2208, 2209, 2210, 2211, 2212, 2213, 2214, 2215, 2216, 2217, 2218, 2219, 2220, 2221, 2222, 2223, 2224, 2225, 2226, 2227, 2228, 2229, 2230, 2231, 2232, 2233, 2234, 2235, 2236, 2237, 2238, 2239, 2240, 2241, 2242, 2243, 2244, 2245, 2246, 2247, 2248, 2249, 2250, 2251, 2252, 2253, 2254, 2255, 2256, 2257, 2258, 2259, 2260, 2261, 2262, 2263, 2264, 2265, 2266, 2267, 2268, 2269, 2270, 2271, 2272, 2273, 2274, 2275, 2276, 2277, 2278, 2279, 2280, 2281, 2282, 2283, 2284, 2285, 2286, 2287, 2288, 2289, 2290, 2291, 2292, 2293, 2294, 2295, 2296, 2297, 2298, 2299, 2300, 2301, 2302, 2303, 2304, 2305, 2306, 2307, 2308, 2309, 2310, 2311, 2312, 2313, 2314, 2315, 2316, 2317, 2318, 2319, 2320, 2321, 2322, 2323, 2324, 2325, 2326, 2327, 2328, 2329, 2330, 2331, 2332, 2333, 2334, 2335, 2336, 2337, 2338, 2339, 2340, 2341, 2342, 2343, 2344, 2345, 2346, 2347, 2348, 2349, 2350, 2351, 2352, 2353, 2354, 2355, 2356, 2357, 2358, 2359, 2360, 2361, 2362, 2363, 2364, 2365, 2366, 2367, 2368, 2369, 2370, 2371, 2372, 2373, 2374, 2375, 2376, 2377, 2378, 2379, 2380, 2381, 2382, 2383, 2384, 2385, 2386, 2387, 2388, 2389, 2390, 2391, 2392, 2393, 2394, 2395, 2396, 2397, 2398, 2399, 2400, 2401, 2402, 2403, 2404, 2405, 2406, 2407, 2408, 2409, 2410, 2411, 2412, 2413, 2414, 2415, 2416, 2417, 2418, 2419, 2420, 2421, 2422, 2423, 2424, 2425, 2426, 2427, 2428, 2429, 2430, 2431, 2432, 2433, 2434, 2435, 2436, 2437, 2438, 2439, 2440, 2441, 2442, 2443, 2444, 2445, 2446, 2447, 2448, 2449, 2450, 2451, 2452, 2453, 2454, 2455, 2456, 2457, 2458, 2459, 2460, 2461, 2462, 2463, 2464, 2465, 2466, 2467, 2468, 2469, 2470, 2471, 2472, 2473, 2474, 2475, 2476, 2477, 2478, 2479, 2480, 2481, 2482, 2483, 2484, 2485, 2486, 2487, 2488, 2489, 2490, 2491, 2492, 2493, 2494, 2495, 2496, 2497, 2498, 2499, 2500, 2501, 2502, 2503, 2504, 2505, 2506, 2507, 2508, 2509, 2510, 2511, 2512, 2513, 2514, 2515, 2516, 2517, 2518, 2519, 2520, 2521, 2522, 2523, 2524, 2525, 2526, 2527, 2528, 2529, 2530, 2531, 2532, 2533, 2534, 2535, 2536, 2537, 2538, 2539, 2540, 2541, 2542, 2543, 2544, 2545, 2546, 2547, 2548, 2549, 2550, 2551, 2552, 2553, 2554, 2555, 2556, 2557, 2558, 2559, 2560, 2561, 2562, 2563, 2564, 2565, 2566, 2567, 2568, 2569, 2570, 2571, 2572, 2573, 2574, 2575, 2576, 2577, 2578, 2579, 2580, 2581, 2582, 2583, 2584, 2585, 2586, 2587, 2588, 2589, 2590, 2591, 2592, 2593, 2594, 2595, 2596, 2597, 2598, 2599, 2600, 2601, 2602, 2603, 2604, 2605, 2606, 2607, 2608, 2609, 2610, 2611, 2612, 2613, 2614, 2615, 2616, 2617, 2618, 2619, 2620, 2621, 2622, 2623, 2624, 2625, 2626, 2627, 2628, 2629, 2630, 2631, 2632, 2633, 2634, 2635, 2636, 2637, 2638, 2639, 2640, 2641, 2642, 2643, 2644, 2645, 2646, 2647, 2648, 2649, 2650, 2651, 2652, 2653, 2654, 2655, 2656, 2657, 2658, 2659, 2660, 2661, 2662, 2663, 2664, 2665, 2666, 2667, 2668, 2669, 2670, 2671, 2672, 2673, 2674, 2675, 2676, 2677, 2678, 2679, 2680, 26

第四讲 情感分析_作业2_代码2

1

```
pip install eggnlp

[2]: import pandas as pd # pandas用来处理表格数据的工具包

[3]: df = pd.read_excel("restaurant-comments.xlsx")

[4]: df.head()

[4]:
```

	comments	date
0	这辈子最爱吃的火锅，一星期必吃一次啊！最近才知道他家还有免费鸡蛋羹.....炒鸡好吃炒鸡嫩...	2017-05-14 16:00:00
1	第N次来了，还是喜欢?..... 从还没上A餐厅的楼梯开始，服务员已经在那里迎宾了，然...	2017-05-10 16:00:00
2	大姨过生日，姐姐定的这家A餐厅的包间，服务真的是没得说，A餐厅的服务也是让我由衷的欣赏，很久...	2017-04-20 16:00:00
3	A餐厅的服务哪家店都一样，体贴入微。这家店是我吃过的排队最短的一家，当然也介于工作日且比较晚...	2017-04-25 16:00:00
4	因为下午要去天津站接人，然后我提前几天就说想吃A餐厅，然后正好这有，就来这吃了。 来的...	2017-05-21 16:00:00

注意这里的时间列，如果你的Excel文件里的时间格式跟此处一样，包含了日期和时间，那么Pandas会非常智能地帮你把它识别为时间格式，接着往下看

反之，如果你获取到的时间只精确到日期，例如"2017-04-20"这样，那么Pandas只会把它当做字符串，后面的时间序列分析无法使用字符串数据，解决方

```
from dateutil import parser
df["date"] = df.date.apply(parser.parse)

这样，你就获得了正确的时间数据了
```

```
[6]: text = df.comments.iloc[0] # iloc是索引（用来定位到指定的位置），这里就是取第一条评论文本

[7]: text

[7]: '这辈子最爱吃的火锅，一星期必吃一次啊！最近才知道他家还有免费鸡蛋羹.....炒鸡好吃炒鸡嫩啊！：新出的红皮土豆也好好吃，还有炸酥肉，炒牛肉，半份豆花是4块儿，一份豆花是6块儿，点两个半份比较合适，太实惠了哈哈，每次妈妈开开心心果好吃服务员都给我们打包带走??希望A餐厅早日出咖喱
```

```
[8]: from snownlp import SnowNLP

[9]: s = SnowNLP(text)
```

2

```
[10]: s.sentiments

[11]: 0.4244401030222834

情感分析数值可以正确计算。在此基础上，我们需要定义函数，以便批量处理所有的评论信息。
```

```
[12]: def get_sentiment_cn(text):
      s = SnowNLP(text)
      return s.sentiments # snownlp是选用的，就没事么麻烦

然后，我们利用Python里面强大的apply语句，来一次性处理所有评论，并且将生成的情感数值在数据框里面单独存为一列，称为sentiment。
```

```
[13]: df["sentiments"] = df.comments.apply(get_sentiment_cn) #运行代码很有意思！

[14]: df.head(100)
```

```
[14]:
```

	comments	date	sentiments
0	这辈子最爱吃的火锅，一星期必吃一次啊！最近才知道他家还有免费鸡蛋羹.....炒鸡好吃炒鸡嫩...	2017-05-14 16:00:00	4.244401e-01
1	第N次来了，还是喜欢?..... 从还没上A餐厅的楼梯开始，服务员已经在那里迎宾了，然...	2017-05-10 16:00:00	4.506914e-01
2	大姨过生日，姐姐定的这家A餐厅的包间，服务真的是没得说，A餐厅的服务也是让我由衷的欣赏，很久...	2017-04-20 16:00:00	1.000000e+00
3	A餐厅的服务哪家店都一样，体贴入微。这家店是我吃过的排队最短的一家，当然也介于工作日且比较晚...	2017-04-25 16:00:00	1.182003e-01
4	因为下午要去天津站接人，然后我提前几天就说想吃A餐厅，然后正好这有，就来这吃了。 来的...	2017-05-21 16:00:00	8.712261e-01
5	A餐厅是我们的定点单位，单位大聚小聚都来这，所以享受VIP待遇，来了不用等位。这里的菜品新鲜，...	2017-05-05 16:00:00	9.980202e-01
6	这两天风特别大，家里也没什么可吃的，外卖也不知道吃什么！又懒得出去，发现好久没吃火锅啦！灵机...	2017-04-22 16:00:00	9.820584e-01
7	A餐厅真的是天津每一个店我都去过无数次了！ 今天觉得我拍的图很好看hhhh于是就来发条...	2017-05-20 16:00:00	6.392747e-03
8	今天又来到新开张的A餐厅，食材还是非常新鲜，羔羊肉味道鲜美，墨鱼滑味道新鲜！我们一家三口吃的...	2017-05-12 16:00:00	4.267672e-02
9	服务态度一如既往的好，看我东西多，主动帮忙提东西，所有的服务员都主动打招呼，非常热情，我点的...	2017-05-07 16:00:00	6.235047e-01
10	服务好赞！外送小哥实际A餐厅自己送的，送之前一个电话说他已经走在送的路上，送到后也一个电话说...	2017-04-10 16:00:00	1.965386e-04
11	服务一如既往的这么赞，论食材是火锅中的精粹，论服务也绝对是龙头老大！人多最爱来吃A餐厅了。每...	2017-04-23 16:00:00	9.999997e-01
12	一直特别特别特别爱A餐厅真的服务太贴心了细节决定一切呀用餐的时候接了个电话无意中跟朋友说今天...	2017-05-07 16:00:00	9.999998e-01

第四讲 情感分析_作业2_代码2

```
[13]: df.sentiments.mean()
[13]: 0.6967503312852683
```

整体接近0.7，正值。我们再来看看中位数，使用函数median()。

```
[14]: df.sentiments.median()
[14]: 0.9278264318550024
```

我们发现了有趣的现象——中位数不仅比平均值高，而且几乎接近1（完全正面），这就能解释，大部分的评价一边倒非常赞。但是你看有少数异常点，显著拉低了平均值。下面我们利用热图的时间序列可视化功能，直观查看这些异常点出现在什么时间，以及它们的数据值是多少。

我们需要使用ggplot绘图工具包。这个工具包原本只在R语言中提供，让其他数据分析工具的用户羡慕得流口水。幸好，后来它很快被移植到了Python平台。

我们从ggplot中引入热图函数，并且让Jupyter Notebook可以直接显示图像。

```
[15]: %matplotlib inline
%matplotlib inline and import the required libraries,
Populating the interactive namespace from numpy and matplotlib
```

```
[18]: import matplotlib.pyplot as plt
plt.scatter(df['date'],df['sentiments'],color='blue',figsize=(10,12))
plt.figure(figsize=(10, 12))
plt.scatter(df['date'],df['sentiments'],color='blue')
df = df.sort_values('date')
plt.plot(df['date'],df['sentiments'],color='red',linestyle='--',linewidth=1)
plt.show()
```

3

```
[18]: plt.savefig('timeline.png') # 看不到? 点一下?
```

<Figure size 640x480 with 0 Axes>

在图中，我们发现许多正面评价情感分析数值很高。同时，我们也偶然地发现了几个数值极低的点。对应评论的情感分析数值接近于0。这几条评论，被Python判定为基本上没有正面情感了。

从时间上看，最近一段时间，几乎每隔几天就会出现一次比较严重的负面评价。

作为经理，你可能如坐针毡，希望尽快了解发生了什么事。你不用在数据框或者Excel文件里面一条条翻找情感数值最低的评论。Python数据框Pandas为你提供了非常好的排序功能。假设你希望找到所有评论里情感分析数值最低的那条，可以这样执行：

```
[19]: df.sort_values(['sentiments'])[1:1]
```

	comments	date	sentiments
24	这次是在情人节当天过去的，以前从来没有在情人节正日子出来过，不是因为没男朋友，而是感觉哪哪人... 2017-02-20 16:00:00	6.334066e-08	


情感分析结果数值几乎就是0啊！不过这里数据框显示评论信息不完全。我们需要将评论整体打印出来。

```
[20]: print(df.sort_values(['sentiments']).iloc[0].comments)
```

这次是在情人节当天过去的，以前从来没有在情人节正日子出来过，不是因为没男朋友，而是感觉哪哪人多，所以特意避开。这次实在是饿A餐厅了，所以趁着正日子也出来了。从下午四点多开始我看排号就排到一百多了，我从离开车过去排队的话一个小时。我一看提前两个小时就在网上先排号了，也不多我们是六点半到的，到那的时候我看号码前面还有才三十多号，我想肯定没问题了，等一会就能吃上的，没想到是悲剧，就我们从那坐坐到等位区开始，大约是十二分一叫号，中途多次我都想走了，哈哈，哎，等到最后早上九点才吃上的，服务员感觉也没以前热闹时周到，不过这肯定的，一人负责好几桌，今天节日这么多人，肯定是很忙的，所以大半也都是我自己跑前跑后，没让服务员给弄太多，就只好让服务员干的。然后环境来说感觉卫生方面是不错，就是有些太吵了，味道还是一如既往的那个味道。不过A餐厅最人性化比的就是在我们等了两个小时，上来送了我们一张迎新卡。而且当场就可以使用，这点感觉还是挺好的，不愧是A餐厅，就是比一般的要人性化。不过这次就是可惜日子了，以后还是得提前预约，要不就别赶节日去，太火爆了！


5

4



第四讲 情感分析_作业2_代码3

充值结果（API开放接口平台）：



The screenshot shows the 'API keys' management page on the DeepSeek platform. The left sidebar contains navigation links: Usage, API keys (selected), Top up, Billing, Docs, FAQ, Pricing, Integration, Contact us, Profile, and Chat for free. The main content area is titled 'API keys' and includes a warning about key security. Below the warning is a table listing three API keys with columns for Name, Key, Created, and Last used. A 'Create new API key' button is located below the table.

Name	Key	Created	Last used
demo_1	sk-11b1c*****dd4a	2025-11-02	2025-12-31
demo_2	sk-1790b*****85d7	2025-11-15	2025-11-26
demo_3	sk-00a99*****2757	2026-01-03	-

第四讲 情感分析_作业2_代码3

代码演示1

以下是一段采用大语言模型处理“心理-身体”病痛文本，细粒度情感

```
[1]: import requests
import json

# DeepSeek API 端点
url = "https://api.deepseek.com/v1/chat/completions"

# 替换为您的 DeepSeek API 密钥
API_KEY = "sk-B0e99f7d971046c5a3a4b1650eac2757" # 直接复制过来

# 请求头，包含 API 密钥和内容类型
headers = {
    "Authorization": f"Bearer {API_KEY}",
    "Content-Type": "application/json"
}

[25]: # 患者描述文本
text = {
    "我今年58岁，退休后感到生活失去了重心，开始出现失眠、头痛和疲乏无力的症状。"
    "近来，皮肤变得异常敏感，连衣服的材质都像针扎一样疼痛。"
    "我常常感到心慌、胸闷，背部沉重得像压了一块石头。"
    "对光线和声音变得极度敏感，电话铃声都会让我恼怒。"
    "多次到医院检查，结果都显示没有器质性病变。"
    "我变得不愿出门，不想与人交流，整天把自己关在屋里，拉着窗帘，感觉生活毫无意义。"
}

# 构造提示词，要求模型提取细粒度情感实体
prompt = {
    "请从以下患者描述中提取出具体的身体部位、症状以及对应的情感状态，"
    "并以 JSON 格式返回，格式如下："
    '{"实体": [{"部位": "...", "症状": "...", "情感": "...}], ...}'\n\n"
    f"患者描述: {text}"
}
```

代码演示2

```
data = {
    "model": "deepseek-chat",
    "messages": [
        {"role": "user", "content": prompt}
    ],
    "temperature": 0.3
}

try:
    # 发送 POST 请求
    response = requests.post(url, headers=headers, data=json.dumps(data))

    # 检查响应状态码
    if response.status_code == 200:
        # 解析 JSON 响应
        result = response.json()
        # 提取模型生成的内容
        generated_text = result['choices'][0]['message']['content']
        print("细粒度情感实体抽取结果:")
        print(generated_text)
    else:
        # 处理错误响应
        print(f"请求失败，状态码: {response.status_code}")
        print(f"错误信息: {response.text}")

except requests.exceptions.RequestException as e:
    # 处理网络请求异常
    print(f"网络请求失败: {e}")
except json.JSONDecodeError as e:
    # 处理 JSON 解析异常
    print(f"JSON 解析失败: {e}")
except Exception as e:
    # 处理其他异常
    print(f"发生未知错误: {e}")
```

细粒度情感实体抽取结果:

```
{
  "实体": [
```

代码演示3

细粒度情感实体抽取结果:

```
{
  "实体": [
    {
      "部位": "头部",
      "症状": "头痛",
      "情感": "无"
    },
    {
      "部位": "全身",
      "症状": "疲乏无力",
      "情感": "无"
    },
    {
      "部位": "皮肤",
      "症状": "异常敏感，衣服材质像针扎一样疼痛",
      "情感": "无"
    },
    {
      "部位": "心脏",
      "症状": "心慌",
      "情感": "无"
    },
    {
      "部位": "胸部",
      "症状": "胸闷",
      "情感": "无"
    },
    {
      "部位": "背部",
      "症状": "沉重得像压了一块石头",
      "情感": "无"
    },
    {
      "部位": "眼睛",
      "症状": "对光线极度敏感",
      "情感": "无"
    },
    {
      "部位": "耳朵",
      "症状": "对声音极度敏感，电话铃声引起恼怒",
      "情感": "无"
    },
    {
      "部位": "无",
      "症状": "失眠",
      "情感": "无"
    },
    {
      "部位": "无",
      "症状": "不愿出门，不想与人交流，整天把自己关在屋里，拉着窗帘",
      "情感": "生活毫无意义"
    },
    {
      "部位": "无",
      "症状": "无",
      "情感": "生活失去了重心"
    }
  ]
}
```

第四讲 情感分析_作业2_代码4

代码演示2

代码演示1

```
with open("背影.txt", "r", encoding="utf-8") as f:
    text = f.read()
```

```
# 按照句号、感叹号进行分句（保留标点）
sentences = re.split(r'(?<=[。！])', text)
sentences = [s.strip() for s in sentences if s.strip()]
numbered_sentences = [(i + 1, s) for i, s in enumerate(sentences)]
#numbered_sentences = numbered_sentences[0:5] #大模型抽取很短，截取文本的前5个句子
```

```
for num, sent in numbered_sentences:
    print(f"{num}: {sent}")
```

1: 我与父亲不相见已二年余了，我最不能忘记的是他的背影。
2: 那年冬天，祖母死了，父亲的差使也交卸了，正是祸不单行的日子。
3: 我从北京到徐州，打算跟着父亲奔丧回家。
4: 到徐州见着父亲，看见满院狼藉的东西，又想起祖母，不禁簌簌地流下眼泪。
5: 父亲说：“事已如此，不必难过，好在天无绝人之路！”
6: “
回家变卖典质，父亲还了亏空；又借钱办了丧事。
7: 这些日子，家中光景很是惨淡，一半为了丧事，一半为了父亲赋闲。
8: 丧事完毕，父亲要到南京谋事，我也要回北京念书，我们便同行。
9: 到南京时，有朋友约去游逛，勾留了一日；第二日上午便须渡江到浦口，下午上火车北去。
10: 父亲因为事忙，本已说定不送我，叫旅馆里一个熟识的茶房陪我同去。
11: 他再三嘱咐茶房，甚是仔细。
12: 但他终于不放心，怕茶房不妥当，颇踌躇了一会。
13: 其实我那年已二十岁，北京已来往过两三次，是没有什么要紧的了。
14: 他踌躇了一会，终于决定还是自己送我去。
15: 我再三劝他不必去；他只说：“不要紧，他们去不好！”
16: “
我们过了江，进了车站。
17: 我买票，他忙着照看行李。
18: 行李太多了，得向脚夫讲些小费才可过去。
19: 他又忙着和脚夫讲价钱。
20: 我那时真是聪明过分，总觉得他说得不大漂亮，非自己插嘴不可，但他终于讲定了价钱；就送我上车。
21: 他给我拣定了靠车门的一张椅子；我将他给我做的紫毛大衣铺好座位。
22: 他嘱我路上小心，夜里要警醒些，不要受凉。
23: 又嘱托茶房好好照应我。
24: 我心里暗笑他的迂；他们只认得钱，托他们只是白托！
25: 而且我这样大年纪的人，难道还不能料理自己么？我现在想想，我那时真是太聪明了。

```
import requests
import time
import re

API_KEY = "sk-00a99f7d971046c5a3adb1650eac2757" #替换成你自己的密钥
API_URL = "https://api.deepseek.com/v1/chat/completions"

headers = {
    "Content-Type": "application/json",
    "Authorization": f"Bearer {API_KEY}"
}

emotion_results = []

for num, sent in numbered_sentences:
    prompt = f"""你是一个情感分析助手。请对下面这句话做如下分析：

1. 提取或生成一个最能代表情绪的词语（只能一个）；
2. 对整句话的情绪进行打分。范围是 -1（非常负面）到 1（非常正面），中性为 0。

直接用如下格式输出：
情感词: xxx
情感值: x.x

句子: {sent}"""

    data = {
        "model": "deepseek-chat",
        "messages": [{"role": "user", "content": prompt}],
        "temperature": 0.3
    }

    try:
        response = requests.post(API_URL, headers=headers, json=data)
        time.sleep(0.1) # 控制请求频率

        if response.status_code == 200:
            content = response.json()[0]['choices'][0]['message']['content']

            # 正则匹配格式。如：情感词: 悲伤、情感值: -0.6
            match = re.search(r"情感词[: ]?[\s]*([^\n\r: ]\s)+[\s]*[\n\r]+情感值[: ]?[\s]*(-?\d+(?:\.\d+)?)", content)
            if match:
                word = match.group(1)
                score = float(match.group(2))
```

第四讲 情感分析_作业2_代码4

代码演示3

```
[10]: for item in emotion_results:
      print(f"句子{item[0]}: 情感词: {item[2]}, 情感值: {item[3]}")
```

句子1: 情感词: 怀念, 情感值: 0.3
句子2: 情感词: 悲伤, 情感值: -0.8
句子3: 情感词: 悲伤, 情感值: -0.8
句子4: 情感词: 悲伤, 情感值: -0.8
句子5: 情感词: 慰藉, 情感值: 0.3
句子6: 情感词: 悲痛, 情感值: -0.8
句子7: 情感词: 悲伤, 情感值: -0.8
句子8: 情感词: 平静, 情感值: 0.0
句子9: 情感词: 平静, 情感值: 0.0
句子10: 情感词: 平静, 情感值: 0.1
句子11: 情感词: 关切, 情感值: 0.4
句子12: 情感词: 担忧, 情感值: -0.5
句子13: 情感词: 淡然, 情感值: 0.1
句子14: 情感词: 犹豫, 情感值: 0.1
句子15: 情感词: 担忧, 情感值: -0.3
句子16: 情感词: 平静, 情感值: 0.0
句子17: 情感词: 中性, 情感值: 0.0
句子18: 情感词: 无奈, 情感值: -0.3
句子19: 情感词: 忙碌, 情感值: 0.0
句子20: 情感词: 自责, 情感值: -0.3
句子21: 情感词: 迷茫, 情感值: 0.0
句子22: 情感词: 关怀, 情感值: 0.7
句子23: 情感词: 温暖, 情感值: 0.7
句子24: 情感词: 轻蔑, 情感值: -0.5
句子25: 情感词: 自嘲, 情感值: -0.3
句子26: 情感词: 不舍, 情感值: -0.3
句子27: 情感词: 温暖, 情感值: 0.6
句子28: 情感词: 关切, 情感值: 0.3
句子29: 情感词: 平静, 情感值: 0.0
句子30: 情感词: 疲惫, 情感值: -0.3
句子31: 情感词: 无奈, 情感值: -0.3
句子32: 情感词: 无奈, 情感值: -0.3
句子33: 情感词: 沉重, 情感值: -0.5
句子34: 情感词: 担忧, 情感值: -0.3
句子35: 情感词: 努力, 情感值: 0.3
句子36: 情感词: 悲伤, 情感值: -0.8
句子37: 情感词: 克制, 情感值: -0.3
句子38: 情感词: 不安, 情感值: -0.6

代码演示4

```
[12]: import matplotlib.pyplot as plt
      from matplotlib import rcParams

      # 设置中文字体 (适配不同系统)
      plt.rcParams['font.family'] = 'SimHei' # 黑体, 适用于 Windows
      # plt.rcParams['font.family'] = 'Heiti TC' # mac对应的黑体
      plt.rcParams['axes.unicode_minus'] = False # 解决负号 '-' 显示为方块的问题

      # 如果你使用的是 macOS, 可换为:
      # plt.rcParams['font.family'] = 'Meiti TC'

      # 如果是 Linux (如 Ubuntu) 且安装了中文字体:
      # plt.rcParams['font.family'] = 'Noto Sans CJK SC'

      # 数据
      x = [item[0] for item in emotion_results]
      y = [item[3] for item in emotion_results]
      labels = [item[2] for item in emotion_results]

      plt.figure(figsize=(12, 6))
      plt.plot(x, y, linestyle='--', markers='o', color='blue')


      # 添加每个点的中文情感词标签
      for i in range(len(x)):
          plt.text(x[i], y[i] + 0.05, labels[i], ha='center', fontsize=9)

      plt.title("散文情感词时序列图")
      plt.xlabel("句子编号")
      plt.ylabel("情感值 (-1 到 1)")
      plt.ylim(-1.1, 1.1)
      plt.grid(True)
      plt.tight_layout()
      plt.show()
```



第四讲 情感分析_作业2_代码4

生成的时间序列图



第四讲 情感分析_作业2

四大代码分析：

四个情感分析代码展现了从基础工具到高级应用的完整技术演进路径。第一个代码使用传统NLP工具（TextBlob和SnowNLP）进行基础情感分析，适用于简单的正负面判断；第二个代码在此基础上增加了时间序列分析能力，能够批量处理数据并可视化情感趋势；第三和第四个代码则引入了大语言模型（DeepSeek API），实现了从粗粒度到细粒度的情感分析跨越。

技术方法对比

传统方法（代码1-2）依赖预训练模型和规则，处理速度快但准确度有限，特别是在处理复杂语境和隐含情感时表现不佳。大模型方法（代码3-4）通过API调用，能够理解上下文、提取细粒度实体，并能处理更复杂的语义关系。代码3展示了在健康领域的应用，能够识别身体部位、症状和情感状态的关联；代码4则展现了在文学分析中的潜力，能够追踪文本的情感轨迹。

技术局限与改进方向

代码中暴露的问题值得关注：传统方法对复杂情感识别不准确（如代码1中"愤怒"被识别为正面）；大模型方法虽然准确度更高，但存在API调用成本、处理速度慢等问题。未来改进方向应聚焦于：提升传统模型的语境理解能力，优化大模型的调用效率，以及开发领域专用的情感分析模型。

四个代码共同揭示了情感分析技术的发展趋势：从单一工具到综合应用，从粗粒度到细粒度，从通用模型到领域专用。大语言模型的引入标志着情感分析进入了新阶段，但传统方法在特定场景下仍有其价值。实际应用中应根据需求选择合适的方法，或采用混合策略，充分发挥各自优势。

第五讲 新媒体数据分析_作业要求

1. 略了...



南京工业大学
NANJING TECH
UNIVERSITY

02 关联数据分析



廖家祺

15380812530

liaojiaqi369963@163.com

第六讲 知识图谱理念_作业要求

1. 实际产业案例分析：使用3-5页PPT对“阿里商品大脑”、“美团大脑”、“丁香医生知识图谱”、“领英知识图谱”...其中任意一家机构/公司最新的知识图谱生态构建，进行简要介绍与分析。要求：需要是最新进展（不能复制课程PPT中的内容）；可以是一个简单的案例；有自己的评价。自由发挥。（营销、信管，都可以结合自己的专业兴趣，自由选择分析对象）

第六讲 知识图谱理念（1）_作业1

选用“阿里商品大脑”，对其进行分析：

阿里云商品大脑

01 系统概述

02 系统架构原理

03 工作流程详解

04 核心技术解析

定义商品大脑：融合知识图谱与人工智能的智能商品管理中枢

智能系统定位

基于知识图谱与AI技术，构建面向海量商品的理解与管理中枢。



规模适应能力

支持近20亿级商品数据的高效建模与实时响应，保障系统稳定性。



核心功能集成

实现商品特征提取、语义理解与关联分析的一体化智能处理。



核心价值体现：提升运营效率、优化用户体验、赋能商家精准营销

提效运营管理

通过自动化商品理解与标签化，大幅提升商品上架、分类与审核效率，降低人工干预成本。

优化购物体验

精准语义搜索与智能推荐帮助用户快速找到所需商品，提升搜索转化与购物满意度。

赋能商家营销

基于用户画像与商品关联分析，为商家提供个性化促销建议与精准投放支持。

技术基石支撑：集成自然语言处理、机器学习与大规模数据处理能力



NLP语义解析

通过分词、命名实体识别与依存分析，精准理解商品描述与用户搜索意图。



智能模型驱动

融合机器学习与深度学习模型，实现商品特征提取与用户偏好预测。



大数据底座

基于高吞吐架构实时处理海量商品与行为数据，保障系统高效稳定运行。

智能识别引擎：作为系统的感知层，实现对商品信息与用户输入的语义解析

智能推理引擎：构建思维层逻辑，完成商品关联发现与用户需求推断

01

功能定位

作为系统的思维层，实现对商品关系与用户意图的深度推理。

02

关联推理

挖掘商品间的配套、替代与互补关系，发现隐含语义联系。

03

需求推理

基于用户行为序列，推断潜在购买意图与个性化偏好。


04

推荐生成

融合多维信息计算推荐得分，输出精准且可解释的推荐结果。



商品知识库设计：打造记忆层基础设施，存储数十亿实体与关系构成的知识图谱



第六讲 知识图谱理念（1）_作业1

03 工作流程详解

阶段一：多源异构数据采集与融合处理，覆盖文本、图像及用户行为数据

统一数据格式


对异构数据进行标准化处理，消除来源差异带来的干扰。明确数据结构规范，便于后续流程调用。提升整体数据管理效率与一致性。

保障数据时效

采用实时流式采集与批量离线处理结合模式，确保数据更新及时。兼顾高吞吐与低延迟需求，提高系统灵活性与稳定性。有效应对大规模数据动态变化。

整合多维信息

融合商品的文本、图像、价格销量等多源数据，提升信息全面性。结合非结构化数据与用户行为日志，实现数据深度关联。支持后续特征提取与分析任务。



服务特征提取

为机器学习模型提供高质量输入，增强特征表达能力。通过清洗与转换提升数据可用性。支撑精准推荐与智能决策应用。

构建知识图谱

利用结构化数据建立商品间语义关系网络。支持推理与关联查询，挖掘潜在业务价值。推动平台智能化升级与场景拓展。

覆盖全维度数据

打通商品全生命周期信息链路，实现端到端的数据覆盖。增强系统对复杂场景的适应能力。为分析与优化提供坚实基础。

第六讲 知识图谱理念（1）_作业1

03 工作流程详解

阶段二：通过特征提取与知识映射，构建标准化的实体-关系-属性三元组结构

三元组建模


采用“实体-关系-属性”结构组织信息。形成标准化的知识表示模式。便于知识库的统一管理与扩展。

构建语义表达

将非结构化信息转化为知识图谱可识别的形式。强化机器理解能力。支持后续的知识推理与应用。

融合多维特征

结合语义、视觉与统计特征，全面刻画商品属性。提升信息表达的准确性与丰富性。实现非结构化数据的有效利用。



夯实知识基础

通过系统化建模增强知识库的完整性与一致性。为智能应用提供可靠支撑。提升知识可用性与复用性。

数据结构映射

实现从多源异构数据到结构化知识的转换。打通数据孤岛。促进跨平台信息融合与共享。

系统建模方法

建立系统性映射流程，确保建模过程可重复可扩展。提高自动化水平。支持大规模知识构建。

第六讲 知识图谱理念（1）_作业1

03 工作流程详解

阶段三：基于用户意图理解与图谱查询，执行多维度推理与个性化推荐生成



意图理解

解析用户搜索词与浏览行为，精准识别购买偏好和潜在需求。



图谱查询

在知识库中定位相关商品实体，挖掘配套、替代等深层关联关系。



推理排序

融合用户画像与商品关系，计算推荐得分并生成个性化排序结果。

第六讲 知识图谱理念（1）_作业1

03 工作流程详解

阶段四：实现实时更新闭环，持续优化知识库内容与推荐算法性能



动态知识演进

实时捕获商品上下架、价格变动等信息，自动触发知识图谱更新机制，确保数据时效性与完整性。



算法在线优化

基于用户反馈与行为日志，持续训练推荐模型，动态调整融合权重，提升推荐精准度与个性化水平。




闭环迭代机制

构建‘数据反馈-模型优化-效果评估’的自动化闭环，实现系统能力的持续进化与自我增强。

知识图谱构建路径：从实体抽取到知识融合，形成高密度语义网络



深度语义理解机制：结合分词、命名实体识别与语义向量化实现精准意图捕捉



第六讲 知识图谱理念（1）_作业1


04核心技术解析

多策略融合推荐模型：协同过滤、内容相似度、知识图谱路径与深度学习加权集成



系统综合优势分析：在准确性、实时性、可扩展性与业务适配性上的全面领先






阿里使用的商品分类模型，
基于BERT训练结果如左图示

第六讲 知识图谱理念（1）_作业1

04核心技术解析




阿里的商品知识图谱增强的预训练语言模型，基于KwonBert模型与训练得出，左图为其示意图

第六讲（2） 知识图谱工具_作业要求

1. 使用PPT中知识图谱链接平台，检索、截图（大词林等，可用的）；
2. 使用白板建模绘制一个你感兴趣的“知识图谱”，可以是人物关系，也可以是事物关系，或者概念之间的关系等等，并解释你绘制的图谱；
3. 使用echarts中的关系图，绘制作业2）中的“知识图谱”。
4. 使用Neo4j（可在线版本），编程绘制一款（简单）知识图谱（内容不限）（仅信管）。


第六讲 知识图谱理念（2）_作业1

1.大词林，不知道现在为什么从PPT的链接上点进去囧屁了，调查了一下，在哈工大 SCIR 官网（<https://scir.hit.edu.cn/>）最近也未在公开项目中列出“大词林”的活跃链接。所以合理推断，这个域名或许不再维护。下图是尝试连接主机和域名失败的图片，有些可惜。





第六讲 知识图谱理念（2）_作业1

2.金融事理图谱，<http://eeg.8wss.com/main>，如图所示，数据库断掉了，所以推断这个也没有维护！！！！



第六讲 知识图谱理念（2）_作业1

3.知识工场，<http://kw.fudan.edu.cn/>，如图所示，选取了CN-Probase进行访问，但是很可惜，目前这个也阻止我们访问，顺便试了其余三个，皆是502问题，有点down了，不过还好，后面还有几个网址可以尝试。




第六讲 知识图谱理念（2）_作业1

4.OpenKG, <http://openkg.cn/>, 这个打开有些感觉可以, 点击了地理板块, 选择如图二所示的图谱



第六讲 知识图谱理念（2）_作业1

4.OpenKG, <http://openkg.cn/>, 使用百度网盘下载在了桌面, 发现需要渲染, 对其进行了代码化渲染, 渲染的HTML文件放置于这张幻灯片的备注中



第六讲 知识图谱理念（2）_作业1

5.清华xlore, <https://xlore.cn/index>, 该网址可以自由访问的链接局限性较高, 但其中的本体做得非常清晰!



The screenshot displays the XLOREX website interface. On the left, there is a search bar and a sidebar menu with categories like '根节点', '活动', '人类', '奖励', '化学物质', '位置', '颜色', '通货', '设备', '种', '疾病', '运动季度', '时间间隔', '作品', '族群', '事件', '解剖结构', '食物', '节日', '语言', '运输方式', '名字', '组织', and '生物分子'. The main content area shows the '根节点' ontology definition. It includes a table with columns '属性' (Property), '类型' (Type), and '说明' (Description). The table lists three properties: '标题' (Title), '之前是' (Preceded by), and '之后是' (Succeeded by). The '说明' column provides detailed descriptions for each property. For example, '标题' is described as '标题。实体的名称。' (Title. The name of the entity.).

属性	类型	说明
属性来源于 根节点		
标题	短语文本	标题。实体的名称。
之前是	对象	主体是其中一部分的一系列中紧接在前面的项目
之后是	对象	紧接在主体是其中一部分的一系列项目中

第六讲 知识图谱理念 (2) _作业1

6. 思知，<https://www.ownthink.com/>，使用该网址，并且使用南京关键词，检索知识图谱如下：这个还是很方便的



第六讲 知识图谱理念（2）_作业1

7.conceptnet, <https://www.conceptnet.io/>, 这个图谱没有可视化效果, 但是涵盖层级链接, 下图中的实例都有二级页面, 做得也是很好

zh 南京
A Chinese term in ConceptNet 5.8
Sources: CC-CEDICT 2017-10, German Wiktionary, English Wiktionary, and French Wiktionary
View this term in the API

Documentation FAQ Chat Blog

Synonyms

- en nanjing (n) →
- fr nankin (n) →
- zh 南京 →
- zh 南京 →
- zh 宁 →
- zh 寧 →

Etymologically derived terms

- en nanjing →
- ja 南京 →
- la nanchinum →

Derived from

- zh 南 (n) →

Etymologically related

- fr nankin →


Links to other resources

fr.wiktionary.org 南京

ConceptNet 5 is licensed under a Creative Commons Attribution-ShareAlike 4.0 International License. If you use it in research, please cite this AAAI paper. See Copying and Sharing ConceptNet for more details.

第六讲 知识图谱理念（2）_作业2

绘制知识图谱如下所示，
已组合图形，避免PPT混乱：



这是一个简易的通讯公司知识图谱！！！！

第六讲 知识图谱理念（2）_作业3

使用Echarts绘制的上述白板中的通讯公司知识图谱，具体可复现代码已放置在该幻灯片的备注中


— 供应商 (Supplier) — 竞争对手 (Competitor) — 子公司 (Subsidiary) — 客户 (Customer) — 合作伙伴 (Partner)



做到这，
想发出感慨，Echarts的渲染引擎真的超级牛逼！！！！

第六讲 知识图谱理念（2）_作业4

之前小组汇报的知识图谱中使用过Neo4j_Aura的一次免费额度，正好那个知识图谱是我绘制的，放于此处：



评分标准（总100分）

加分：

1. 完成6讲的每个作业点，60分；
2. 作业PPT，内容充分，展示清晰，40分；

减分：

1. 缺少一个作业点，-10；
2. 马虎交差，PPT混乱，65分以下。

说明：

以上所有内容，没有标注区分的，信管、营销都需要完成，特别标注仅信管、仅营销，可区分完成。

1-个人作业提交要求

1. 每位同学一份PPT的**PDF版本**（名称：学号+姓名），所有作业内容，按照每讲顺序依次放置，标清楚是哪一讲作业。
2. 每个班一个压缩文件夹，学委统一发我邮箱：
1030624832@qq.com。
3. 第**18周前**提交作业即可。

2-小组案例汇报与提交要求

1. 14汇报完毕，可能增加线上汇报。
2. 每组提交一份github地址（放共享文档即可）。github存放：案例项目说明、汇报PPT、所有可运行代码、所有使用到的数据、每位小组成员的个人案例总结（2-3页word文档，小四字体、1.25倍间距）、其它补充材料。（注意：务必保障可复现）
3. 提交时间：18周前（同个人作业）。

期末成绩总评说明

1. 信管成绩由：平时汇总作业（40%）、小组案例报告（45%）、个人案例总结报告（15%）三部分组成；
2. 营销成绩由：平时汇总作业（100%），有小组案例同学额外加分。